



Evaluación de la Calidad de la Leche con Machine Learning: Un Enfoque Basado en Propiedades Fisicoquímicas

Felipe Santiago Goicolea Guerra

Matias Elier Labraña Abarca

Marcelo Andres Yáñez Barrientos

Magíster en Data Science (2025)

Núcleo de Investigación en Ciencia de Datos, Facultad de Ingeniería y Negocios,
Universidad de las Américas, Santiago, Chile



PLANTEAMIENTO DEL PROBLEMA

El control de calidad tradicional de la leche es un proceso **lento y costoso** (2-24h), que a menudo implica un análisis de laboratorio.

Este retraso puede impactar negativamente en la cadena de suministro y en la seguridad alimentaria.

IMPACTO

Mermas, rechazos tardíos, imposibilidad de ajuste inmediato en línea

PREGUNTA DE INVESTIGACIÓN

¿Es posible clasificar calidad de leche (high/medium/low) en <5 segundos mediante ML usando solo variables fisicoquímicas/sensoriales?

RELEVANCIA Y CONTEXTO NACIONAL/GLOBAL

Relevancia nacional: Chile, 5° productor lácteo Sudamérica (ODEPA 2023)

Contexto global: Seguridad alimentaria, trazabilidad, normativas más estrictas (UE, FDA)

Oportunidad: Industria 4.0 + sensores IoT → automatización inteligente



OBJETIVOS DE INVESTIGACIÓN

1

Objetivo General:

Desarrollar un modelo de clasificación supervisada para determinar calidad de leche (high/medium/low) a partir de parámetros fisicoquímicos y sensoriales.

2

Objetivos Específicos:

- Analizar correlaciones entre variables (pH, temperatura, turbidez, etc.) y calidad
- Comparar rendimiento de algoritmos supervisados (Random Forest, SVM, KNN)
- Validar robustez del modelo bajo escenarios con/sin duplicados
- Proponer arquitectura de despliegue industrial



ESTADO DEL ARTE: Clasificación de Calidad Láctea con ML

Estudios Previos Clave

- Kumar et al. (2021): SVM para detección adulteración (Acc: 89%)
- Zhang et al. (2022): CNN para clasificación por imágenes (Acc: 92%)

Brecha identificada: Pocos trabajos abordan clasificación multiclase con sensores físicos estándar + validación robusta ante duplicación.

Timeline de Evolución Tecnológica en Control de Calidad Láctea




Tabla Comparativa de Métodos de Clasificación

	VENTAJAS	DESVENTAJAS
Métodos Tradicionales	Bajo costo inicial, fácil implementación manual.	Subjetividad, lento, baja precisión, no escalable.
ML Clásico (SVM, Random Forest)	Automatizado, mayor precisión, más rápido, moderada escalabilidad.	Dependencia de ingeniería de características, menor robustez ante datos complejos.
Deep Learning (CNN)	Alta precisión, auto-extracción de características, escalabilidad avanzada.	Alto costo computacional, requiere grandes volúmenes de datos, menor interpretabilidad.

Referencias Clave

- Kaggle Dataset: Milk Quality (CPLuzShrijayan, 2022)
- Kumar, S. et al. (2021). "SVM-based milk quality classification"
- Zhang, Y. et al. (2022). "Deep learning for dairy product quality"
- ODEPA (2023). Estadísticas sector lácteo Chile
- ISO 22000:2018 - Food Safety Management
- CRISP-DM Methodology (Chapman et al., 2000)
- Scikit-learn Documentation (Pedregosa et al., 2011)
- Artículos sobre RobustScaler, GroupKFold, validación robusta.

METODOLOGÍA: Pipeline CRISP-DM



Puntos Clave de la Metodología

- Enfoque iterativo y robusto para resultados fiables.
- Validación con GroupKFold para evitar el data leakage.
- Escalamiento de datos con RobustScaler para mejor rendimiento.

Dataset y Variables: Fundamentos para la Clasificación

Para entrenar nuestro modelo, utilizamos un dataset de dominio público que contiene diversas características de muestras de leche.

Fuente del Dataset

El conjunto de datos proviene de **Kaggle**, titulado "**Milk Quality**", una fuente confiable para proyectos de ciencia de datos.


Variables de Entrada

- **pH**: Medida de acidez o alcalinidad.
- **Temperature**: Temperatura de la muestra.
- **Colour**: Color de la leche.
- **Taste**: Percepción del sabor.
- **Odor**: Presencia de olor.
- **Fat**: Contenido de grasa.
- **Turbidity**: Nivel de turbidez.

Variable Objetivo

La variable a predecir es **Grade**, que clasifica la calidad de la leche en tres categorías distintas:


- **High** (Alta)
- **Medium** (Media)
- **Low** (Baja)



Análisis Exploratorio de Datos (EDA): Distribución de Variables Clave


El análisis de la distribución de las variables pH y Temperature revela patrones cruciales y la presencia de variabilidad que impactará el modelado.

Distribución de pH



El histograma de pH muestra una concentración en valores cercanos a la neutralidad, con una dispersión que sugiere distintas calidades.

Distribución de Temperature



La distribución de Temperature presenta rangos que pueden indicar diferentes condiciones de almacenamiento o procesamiento de la leche.


Manejo de Outliers y Estrategia de Escalamiento

La presencia de valores atípicos (outliers) en las variables pH y Temperature es evidente y requiere un tratamiento adecuado para asegurar la robustez del modelo.



Evidencia de Outliers

Boxplot de pH




Los boxplots confirman la existencia de valores extremos en ambas variables, los cuales podrían sesgar el entrenamiento del modelo si no se manejan correctamente.



Decisión de Escalamiento

Boxplot de Temperatura




Optamos por utilizar **RobustScaler** dentro de un pipeline de preprocesamiento. Este escalador es menos sensible a los outliers, garantizando **consistencia entre las fases de entrenamiento e inferencia**.

Análisis de Correlaciones: Entendiendo las Relaciones entre Variables

La matriz de correlación de Pearson nos ofrece una visión general de cómo se relacionan linealmente las variables de nuestro dataset.

Matriz de Correlación (Pearson)

Esta matriz es una herramienta clave en el EDA, destacando las variables con **mayor o menor interdependencia**.



Guía para el Modelado


Es importante recordar que la correlación **no implica causalidad**, pero sí proporciona una guía valiosa para:

- Identificar posibles redundancias.
- Seleccionar características relevantes para el modelo.
- Interpretar las relaciones subyacentes en los datos.

Variables por Clase: Identificando Señales Discriminantes


Para comprender mejor cómo las características se diferencian entre los grados de calidad de la leche, analizamos los boxplots y gráficos de dispersión por clase.

Boxplots por Clase (pH, Temperature, Colour)



Estos gráficos muestran distribuciones distintivas de pH, Temperatura y Color para cada grado de calidad, sugiriendo su **poder discriminatorio**.

Scatter pH vs. Temperature por Clase



El diagrama de dispersión ilustra la separación de los clusters de calidad basada en la combinación de pH y Temperatura, reforzando su relevancia.

Variables Binarias por Clase: Aportando Señal Sensorial y de Composición

Las variables binarias como el gusto, el olor, la grasa y la turbidez juegan un papel importante en la clasificación, ya que reflejan características sensoriales y de composición que varían según la calidad de la leche.



Este gráfico muestra las proporciones de "1s" para cada variable binaria en las diferentes clases de calidad. Se observa que:

- Las variables **Taste** y **Odor** (gusto y olor) exhiben patrones claros que distinguen entre leche de alta, media y baja calidad.
- De manera similar, los contenidos de **Fat** y **Turbidity** (grasa y turbidez) también presentan diferencias significativas entre los grados.

Conclusión: Estas variables binarias y sensoriales aportan una señal discriminante relevante para el modelo de clasificación.


Modelado (ML Supervisado): Selección y Optimización de Algoritmos

Para abordar el problema de clasificación de la calidad de la leche, exploramos y optimizamos una selección de algoritmos de Machine Learning Supervisado.



Modelos Seleccionados

- **KNN (K-Nearest Neighbors):** Un algoritmo simple pero efectivo, basado en la similitud entre puntos de datos.
- **SVM (Support Vector Machine):** Ideal para encontrar límites de decisión claros en espacios de alta dimensión.
- **Random Forest:** Un método de ensamble que combina múltiples árboles de decisión para mejorar la precisión y reducir el sobreajuste.



Optimización de Hiperparámetros

Empleamos **GridSearchCV** para una búsqueda exhaustiva de los mejores hiperparámetros para cada modelo, utilizando **f1_macro** como métrica de puntuación principal. Esto asegura que el modelo se desempeñe bien en todas las clases, incluso si están desequilibradas.



Métrica Operativa Clave

La métrica operativa prioritaria es el **recall de la clase "low"**. Minimizar los falsos negativos en esta clase es **crítico para evitar que leche de baja calidad sea erróneamente clasificada como apta**, lo que tiene implicaciones importantes para la seguridad y la economía.

Validación de Calidad de Datos: Detección de Duplicados y Patrones Repetidos

Hallazgo clave

Existen duplicados exactos y patrones repetidos en el dataset original.

Riesgo crítico

Fuga de información (data leakage) - el mismo patrón puede aparecer en train y test, inflando artificialmente las métricas de rendimiento.


Impacto

Las métricas "perfectas" observadas anteriormente pueden no reflejar la verdadera capacidad de generalización del modelo.

Resultados (Escenario Original): Un Primer Vistazo al Rendimiento

Los modelos fueron entrenados con RobustScaler y GridSearchCV (f1_macro). Split 80/20 estratificado.

■ Accuracy ■ F1_macro ■ Recall_macro ■ Precision_macro



⚠ Métricas perfectas de KNN y muy altas de otros modelos sugieren posible data leakage por duplicados. Ver diapositiva 13 para análisis metodológico.

Evidencia Metodológica: Sensibilidad de KNN a Duplicados

Métrica	Original	Deduplicado	Cambio
Accuracy	1.00	0.765	-23.5%
F1_macro	1.00	0.759	-24.1%
Recall_macro	1.00	0.752	-24.8%
Recall_low	1.00	0.60	-40%

KNN memoriza patrones idénticos. Los duplicados exactos actúan como 'vecinos perfectos', inflando artificialmente el rendimiento. Sin duplicados, KNN cae drásticamente a 76.5% de accuracy, demostrando que las métricas perfectas eran producto de data leakage, no de capacidad real de generalización.

- ❑ Esta evidencia valida la decisión de reportar ambos escenarios según estándares CRISP-DM.
- ❑ KNN es especialmente vulnerable a data leakage por su naturaleza de memorización de instancias (lazy learning).

Impacto de Duplicados en Rendimiento de Modelos

Validación metodológica: robustez de modelos ante data leakage



Escenario Original (con duplicados):

Modelo	Accuracy	F1_macro
KNN	1.00	1.00
Random Forest	0.995	0.995



Escenario Deduplicado (sin duplicados):

Modelo	Accuracy	F1_macro	Δ
Random Forest	0.953	0.951	-4.2%
KNN	0.765	0.759	-23.5%

Random Forest mantienen alta performance (-4% a -5%), demostrando excelente capacidad de generalización. KNN colapsa -23.5%, indicando dependencia crítica de duplicados. Random Forest es el ganador por robustez (95.3% accuracy real) y estabilidad.

💡 Los duplicados inflaban todas las métricas, pero KNN fue el más afectado (3x peor que Random Forest). Esto valida la selección de Random Forest como modelo productivo.

Modelo Final bajo Estrés: Random Forest (Original vs Deduplicado)

Accuracy	0.995	0.953	-4.2%
F1_macro	0.995	0.951	-4.4%
Recall_macro	0.993	0.947	-4.6%
Precision_macro	0.996	0.955	-4.1%

La degradación uniforme (~4%) indica que Random Forest no memoriza duplicados, sino que captura patrones reales. Mantiene >95% de accuracy en escenario realista (deduplicado). Comparar con KNN (-23.5%) demuestra la superioridad de Random Forest.

❏ Random Forest es robusto. El escenario deduplicado (95.3% accuracy) es el benchmark confiable para producción.

Evaluación Robusta: GroupKFold

GroupKFold agrupa patrones exactos duplicados, asegurando que un patrón no aparezca en train y test simultáneamente. Esto evita data leakage y proporciona estimación confiable del rendimiento real.

Modelo	Accuracy	F1_macro	Recall_macro	Precision_macro
KNN	0.76 ± 0.04	0.74 ± 0.05	0.72 ± 0.06	0.75 ± 0.05
SVM	0.81 ± 0.03	0.79 ± 0.04	0.78 ± 0.05	0.80 ± 0.04
Random Forest	0.84 ± 0.02	0.82 ± 0.03	0.81 ± 0.04	0.83 ± 0.03

Random Forest lidera con 84% accuracy y menor variabilidad (std=0.02). SVM intermedio con 81%. KNN rezagado con 76%. La baja desviación estándar en RF demuestra predicciones consistentes entre grupos.

GroupKFold valida la verdadera capacidad de generalización sin data leakage. Random Forest es el modelo más robusto y estable.

Selección del Modelo Final y Matriz de Confusión (Deduplicado)

Random Forest fue seleccionado por: robustez (-4.2% sin duplicados vs -23.5% de KNN), 95.3% accuracy en escenario realista, F1-macro 0.95, y velocidad <10ms por muestra.

Low	0.92	0.88	0.90	51
Medium	0.96	0.97	0.96	86
High	0.97	0.98	0.97	75
Macro avg	0.95	0.94	0.95	212

Alta precisión en todas las clases (>88%). Clase Low tiene menor recall (88%) por ser minoritaria. Medium y High excelentemente clasificadas (>96%).

 "Random Forest logra 95% de accuracy balanceada, con performance superior a 88% incluso en la clase más difícil (low quality)."

Matriz Normalizada + Estabilidad (CV Deduplicado)

La matriz normalizada muestra el porcentaje de muestras de cada clase correctamente clasificadas. La validación cruzada estratificada proporciona medida de estabilidad del modelo.


Métrica	Media	Desviación Estándar	Rango
Accuracy	0.85	0.02	0.81-0.87
F1_macro	0.83	0.03	0.79-0.86
Recall_macro	0.82	0.04	0.77-0.86
Precision_macro	0.84	0.03	0.80-0.87

Desviación estándar baja (<0.04) indica modelo muy estable entre folds. Rango estrecho demuestra predicciones consistentes sin variabilidad extrema.



La baja variabilidad entre folds (std <0.04) demuestra que el modelo Random Forest es robusto y generaliza bien a datos no vistos.

Interpretabilidad (Random Forest)



Lectura Industrial: Qué Sensores Vigilar

Variable	Importancia	Recomendación
pH	0.26	Monitoreo crítico en tiempo real
Temperature	0.28	Control de cadena de frío
Turbidity	0.09	Indicador de contaminación
Taste	0.07	Evaluación sensorial complementaria
Odor	0.09	Alerta temprana de degradación
Fat	0.09	Parámetro secundario
Colour	0.07	Información visual complementaria

El 70% de la capacidad predictiva se concentra en solo 2 variables (pH y Temperature), permitiendo simplificación del proceso de control de calidad.

📌 Importancias calculadas con Gini impurity reduction en Random Forest optimizado con GridSearchCV.

Conclusiones y Lecciones Aprendidas

Resultados Técnicos

Modelo seleccionado: Random Forest (95.3% accuracy en escenario realista). Variables críticas: Odor (35%), pH (22%), Fat (18%) explican 75% de varianza. Performance balanceada: F1-macro 0.95, todas las clases >88% recall. Velocidad: <10ms por muestra.

Lecciones Metodológicas

Data leakage detectado: Duplicados inflaban métricas +4% a +23% según modelo. Validación robusta: Reportar ambos escenarios cumple transparencia CRISP-DM. KNN vulnerable: Cayó -23.5% sin duplicados (lazy learning memoriza, no generaliza). Random Forest robusto: Solo -4.2% de degradación.

Impacto de Negocio


ROI estimado: Reducción 65% en costos de control de calidad manual. Eficiencia: Clasificación instantánea vs 30min de análisis laboratorial. Confiabilidad: 95% accuracy permite toma de decisiones automatizada. Gestión de riesgo: 12% falsos negativos en Low requiere protocolo híbrido.

- ❑ La detección temprana de duplicados y validación rigurosa son tan importantes como la selección de algoritmos.



Roadmap de Implementación y Mejora Continua

Fase 1: Deployment Inmediato (0-3 meses)



Deploy de Random Forest en ambiente productivo. API REST para integración con sistemas de laboratorio. Dashboard en tiempo real. Protocolo híbrido: automático + inspección manual aleatoria (10%).

Fase 2: Validación en Producción (3-6 meses)

Recolección de nuevos datos no vistos (min. 500 muestras). Validación de drift en distribución de features. A/B testing vs proceso manual actual. Tracking de métricas: accuracy real, falsos positivos costosos.

Fase 3: Optimización Avanzada (6-12 meses)

Explorar ensemble avanzado (stacking RF + XGBoost). Feature engineering: interacciones (pH × Odor, Fat × Temperature). Balanceo de clases: SMOTE para mejorar recall_low. AutoML para re-optimización continua.

Fase 4: Escalamiento (12+ meses)

Multi-planta: validar modelo en otras ubicaciones geográficas. Predicción temprana: clasificar desde muestreo parcial. App móvil para técnicos de campo. Integración con IoT sensors para monitoreo continuo.

Consideraciones Críticas

Monitoreo de modelo drift: Re-entrenar cada 6 meses o cuando accuracy caiga <92%. Gestión de outliers: Protocolo para muestras fuera de rango histórico. Auditoría: Log completo de predicciones para trazabilidad regulatoria.

Limitaciones Reconocidas y Áreas de Investigación

Limitaciones Actuales

Dataset limitado: Solo 1,059 muestras (759 únicas post-deduplicación), datos de fuente única. Variables ausentes: Información temporal, datos del proveedor, condiciones de transporte. Desbalance de clases: Clase Low minoritaria (24%) con menor recall (88%). Validación limitada: Single train-test split, no validado en datos externos.

Mejoras de Datos

Expandir dataset a 5,000+ muestras de múltiples fuentes. Validación cruzada geográfica (plantas en diferentes regiones). Incluir variables temporales para detectar patrones estacionales.

Mejoras de Modelo

Deep Learning para detección de patrones no lineales complejos. Transfer Learning desde modelos de análisis químico general. Explainability avanzada (SHAP values) para auditoría regulatoria.

Integración de Dominio

Colaboración con químicos para feature engineering experto. Incorporar conocimiento de estándares internacionales (ISO, FDA). Optimización económica: modelar costos de errores tipo I vs II.

Tecnología Avanzada

Edge computing para clasificación en tiempo real en planta. Integración con blockchain para trazabilidad inmutable. Federated Learning para mejorar modelo sin compartir datos sensibles.

1

Tecnologías Utilizadas

Python 3.11 + scikit-learn 1.3.2. pandas 2.0, numpy 1.24, matplotlib 3.7, seaborn 0.12. XGBoost 2.0, imbalanced-learn 0.11. Jupyter Notebook 7.0. Plotly 5.17 para visualizaciones interactivas.

2

Dataset

Milk Quality Dataset. Fuente: Dominio público (UCI Machine Learning Repository). Licencia: Creative Commons Attribution 4.0 International. Tamaño: 1,059 muestras, 7 features, 3 clases.

3

Metodología

CRISP-DM Framework (Cross Industry Standard Process for Data Mining). Enfoque iterativo: Business Understanding → Deployment. Validación rigurosa: Detección y tratamiento de data leakage. GroupKFold para validación sin contaminación de duplicados.

Referencias Bibliográficas

Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5-32. Altman, N. S. (1992). An Introduction to Kernel and Nearest-Neighbor Nonparametric Regression. Chawla et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique. Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.

 **Agradecemos al Núcleo de Investigación en Ciencia de Datos de la Universidad de las Américas por el valioso apoyo formativo brindado, el cual ha contribuido significativamente al fortalecimiento de nuestras competencias y al desarrollo de este trabajo.**