

Evaluación de la Calidad de la Leche mediante Machine Learning: Un Enfoque Fisicoquímico y Sensorial

Felipe Santiago Goicolea Guerra, Matías Elier Labraña Abarca, Marcelo Andrés Yáñez Barrientos
Facultad de Ingeniería y Negocios
Universidad de las Américas
Santiago, Chile
Emails: fgoicolea@gmail.com,
labranamatias91@gmail.com,
myanez91@gmail.com

Agradecemos al Núcleo de Investigación en Ciencia de Datos de la Universidad de las Américas por el apoyo formativo brindado.

Resumen—The dairy industry requires rapid and accurate methods to ensure food safety. This research proposes an automated classification system based on supervised machine learning to categorize milk quality into three levels: Low, Medium, and High. Using a physicochemical and sensorial dataset and following the CRISP-DM methodology, the study highlights the use of Random Forest combined with robust scaling. The results achieve 99.5 % accuracy in the original dataset, identifying pH and temperature as the most influential factors. This approach provides a scalable tool for real-time monitoring in the supply chain.

Index Terms—Machine Learning, Milk Quality, Random Forest, Physicochemical Analysis, CRISP-DM

Resumen—La industria láctea requiere métodos rápidos y precisos para garantizar la seguridad alimentaria [1]. Esta investigación propone un sistema de clasificación automatizado basado en aprendizaje automático supervisado para categorizar la calidad de la leche en tres niveles (Low, Medium, High). Utilizando un conjunto de datos con parámetros fisicoquímicos y sensoriales y la metodología CRISP-DM [2], se destaca el uso de Random Forest con escalado robusto. Los resultados logran una precisión del 99.5 % en el conjunto original, identificando al pH y la temperatura como factores críticos, y proporcionan una herramienta escalable para monitoreo en tiempo real [3].

I. INTRODUCCIÓN

La calidad de la leche es un factor crítico para la salud pública, la seguridad alimentaria y la estabilidad económica del sector lácteo a nivel global [4]. Alteraciones en parámetros clave como pH, temperatura, turbidez, grasa, sabor y olor pueden indicar contaminación microbiana, adulteración o degradación temprana, lo que compromete la inocuidad y genera pérdidas económicas significativas [5], [6]. Según los estándares internacionales del Codex Alimentarius, el monitoreo continuo de estos parámetros es esencial para garantizar la calidad e inocuidad en toda la cadena de suministro [1].

Sin embargo, los métodos tradicionales de análisis (e.g., pruebas microbiológicas, cromatografía, titulación) son costosos, requieren laboratorios especializados y tardan horas o días en entregar resultados, limitando su aplicación en

monitoreo en tiempo real, especialmente en granjas o plantas de procesamiento de pequeña y mediana escala [5]. Esta demora dificulta la detección temprana de productos fuera de norma y aumenta el riesgo de recalls o rechazos en la cadena de valor.

Los avances en ciencia de datos y aprendizaje automático ofrecen alternativas eficientes y escalables mediante algoritmos supervisados que procesan datos fisicoquímicos y sensoriales para clasificar la calidad de forma automática [7]. Modelos como Random Forest han demostrado robustez y superioridad en conjuntos de datos biológicos y con multicolinealidad, superando a métodos estadísticos tradicionales en precisión e interpretabilidad [8].

Este trabajo adopta la metodología CRISP-DM [2] – ampliamente utilizada en proyectos de minería de datos y adaptable a aplicaciones de machine learning– para desarrollar un sistema de clasificación automatizado de la calidad de la leche en tres niveles (Low, Medium, High) a partir de un conjunto de datos público con parámetros fisicoquímicos y sensoriales [9]. El enfoque enfatiza el preprocesamiento riguroso (incluyendo deduplicación y escalado robusto), la comparación de modelos y el análisis de importancia de características para identificar drivers críticos como pH y temperatura.

Las principales contribuciones de este estudio son:

- La aplicación estructurada de CRISP-DM en un contexto lácteo, destacando el impacto crítico de la deduplicación de datos para evitar *data leakage* y sobreestimación del rendimiento predictivo.
- La demostración de la superioridad de Random Forest combinado con escalado robusto (`RobustScaler`) en presencia de *outliers* y multicolinealidad moderada entre variables sensoriales.
- Un análisis detallado de importancia de características que confirma pH y temperatura como predictores dominantes (>55 % de contribución combinada), alineado con su rol bioquímico en estabilidad coloidal y control microbiano [5], [6].

- La provisión de una herramienta interpretable y escalable para monitoreo en tiempo real, potencialmente integrable en sistemas de *edge computing* en entornos industriales de bajo recurso [3].

El resto del documento se organiza como sigue: la Sección II presenta trabajos relacionados; la Sección III detalla la metodología; la Sección IV discute resultados y limitaciones; y la Sección V concluye con implicaciones y líneas futuras.

II. TRABAJOS RELACIONADOS

La aplicación de técnicas de aprendizaje automático para evaluar la calidad de la leche ha ganado relevancia en los últimos años, impulsada por la necesidad de métodos rápidos, no destructivos y escalables frente a los análisis tradicionales basados en laboratorio [1], [5], [6].

Estudios recientes han explorado el uso de algoritmos supervisados para predecir la calidad láctea a partir de parámetros fisicoquímicos y sensoriales. Rajini et al. [3] revisan enfoques de machine learning para garantía de calidad en productos lácteos, destacando la utilidad de modelos como Random Forest en contextos de monitoreo y clasificación, aunque sin profundizar en problemas específicos de preprocesamiento como duplicados masivos o escalado robusto ante *outliers*.

Datasets públicos similares al utilizado en este trabajo [9] –que incluyen variables como pH, temperatura, sabor, olor, grasa, turbidez y color– han sido empleados para tareas de clasificación ternaria (Low, Medium, High). Estos conjuntos permiten aplicar modelos como Random Forest, SVM y k-NN, reportando altas precisiones en escenarios no limpios, pero a menudo sin analizar el impacto de duplicados exactos que inducen *data leakage* y sobreestimación del rendimiento [3].

Random Forest se destaca por su robustez en datos biológicos y su capacidad para manejar multicolinealidad y dependencias entre características, superando a métodos lineales o más simples en aplicaciones relacionadas con calidad alimentaria [8]. Además, su interpretabilidad mediante medidas de importancia de características (impureza de Gini) permite identificar drivers críticos como pH y temperatura, alineados con su rol bioquímico en estabilidad coloidal, actividad microbiana y proliferación bacteriana [5], [6].

Sin embargo, la mayoría de los trabajos previos no abordan sistemáticamente la presencia masiva de duplicados en datasets públicos (que puede superar el 90 %), ni cuantifican el efecto de la deduplicación en la generalización real del modelo. Tampoco integran de forma explícita técnicas de escalado robusto para mitigar *outliers*, ni siguen estrictamente metodologías como CRISP-DM para garantizar reproducibilidad y reducción de riesgos en la cadena de suministro [2], [7].

Este trabajo contribuye precisamente en estos aspectos: aplica CRISP-DM de manera rigurosa, evalúa comparativamente el desempeño en conjuntos crudo y deduplicado (evidenciando la caída de precisión de 99.5 % a 82.4 %), demuestra la superioridad de Random Forest con escalado robusto ante multicolinealidad moderada entre variables sensoriales, y resalta pH y temperatura como predictores dominantes (>55 % de




Figura 1. Distribución de las variables fisicoquímicas principales. El pH exhibe una distribución multimodal, reflejando diferentes estados de acidez/degradación; la temperatura se concentra en rangos típicos de refrigeración (4–8 °C) y procesos térmicos.

contribución combinada), con énfasis en aplicaciones escalables para monitoreo en tiempo real en entornos industriales.

III. METODOLOGÍA

Con el fin de asegurar la reproducibilidad de este estudio, se describen en detalle el entorno de trabajo, la preparación de los datos, las herramientas utilizadas y los procedimientos seguidos.

III-A. Entorno computacional

Los experimentos se realizaron en un equipo con Windows 11, procesador Intel i7 y 16 GB de memoria RAM. La implementación se llevó a cabo en Python 3.11 utilizando la distribución Anaconda. Todo el flujo de trabajo fue documentado en Jupyter Notebooks [10].

Este estudio sigue estrictamente la metodología CRISP-DM [2], que proporciona un marco estructurado y reproducible para proyectos de minería de datos y aprendizaje automático. Las fases relevantes implementadas son: comprensión del negocio y de los datos, preparación de datos, modelado, evaluación y (parcialmente) despliegue.

III-B. Comprensión del Negocio y de los Datos

El objetivo del negocio es desarrollar un clasificador automático de calidad de leche (Low, Medium, High) basado en parámetros fisicoquímicos y sensoriales, capaz de apoyar decisiones rápidas en la cadena de suministro láctea para reducir riesgos de inocuidad y pérdidas económicas [5].

El conjunto de datos utilizado es público y accesible [9]. Contiene 1059 instancias originales con 8 características predictoras:

- **Fisicoquímicas:** pH, temperatura (°C), grasa (%), sólidos totales (%), sólidos no grasos (%).
- **Sensoriales:** sabor, olor, turbidez, color (codificados categóricamente o numéricamente según el dataset).

La variable objetivo es Grade (categórica: Low, Medium, High). El dataset presenta un desbalance moderado en la distribución original de clases y un alto porcentaje de duplicados exactos (92.16 %), lo que sugiere posible redundancia o artefactos de recolección.




Figura 2. Matriz de correlación de Pearson entre variables predictoras. Se observa independencia relativa entre pH y temperatura (correlación $\approx 0,24$), junto con multicolinealidad moderada entre variables sensoriales (e.g., Odor-Turbidity $r = 0,46$, Fat-Turbidity $r = 0,33$). Estas dependencias justifican el uso de Random Forest, robusto ante multicolinealidad y no linealidades.




Figura 3. Comparación de la distribución de la variable objetivo Grade (Low, Medium, High) en el conjunto original versus deduplicado. La deduplicación reduce drásticamente el tamaño, pero preserva la estructura relativa de clases.

III-C. Recolección y Preprocesamiento de Datos

El dataset se obtuvo directamente de la fuente pública [9]. Las operaciones de preprocesamiento, implementadas con pandas y scikit-learn [11], incluyeron:

- **Eliminación de duplicados exactos:** Se removieron 92.16 % de las filas (quedando ≈ 82 –100 instancias únicas), para prevenir *data leakage* y sobreajuste artificial [12]. La Figura 3 compara la distribución de clases antes y después de la deduplicación.
- **Manejo de valores faltantes:** No se detectaron valores nulos en el dataset.
- **Codificación de variables categóricas:** Las variables sensoriales (sabor, olor, turbidez, color) se codificaron numéricamente si no lo estaban originalmente.
- **Escalado:** Se aplicó `RobustScaler` (basado en mediana e IQR) a todas las variables numéricas para mitigar el impacto de *outliers* y rangos dispares, especialmente en temperatura y pH [13].

Se generaron dos escenarios para comparación: (1) dataset original (con duplicados), y (2) dataset deduplicado (instancias únicas).

III-D. Modelado y Optimización de Hiperparámetros

Se evaluaron tres algoritmos supervisados de clasificación:

- **Random Forest** [8] (ensemble basado en árboles de decisión, robusto a multicolinealidad y *outliers*).
- **k-Nearest Neighbors (k-NN)** [12] (basado en distancia, sensible a escalado y dimensionalidad).
- **Support Vector Machine (SVM)** [14] (con kernel RBF o lineal, efectivo en espacios no lineales pero computacionalmente intensivo).

Todos los modelos se implementaron mediante *pipelines* de scikit-learn para garantizar reproducibilidad, evitar fugas de datos y aplicar consistentemente el escalado. La evaluación se realizó con validación cruzada estratificada de 5 folds (preservando la proporción de clases en cada pliegue), adecuada para el desbalance moderado observado en la variable Grade.

La métrica principal de optimización fue el F1-score macro (promedio no ponderado de F1 por clase), que equilibra precisión y recall en problemas multiclass con clases desbalanceadas.

La búsqueda de hiperparámetros se realizó con `GridSearchCV`, explorando rangos razonables y representativos basados en literatura estándar y pruebas preliminares para evitar exploraciones excesivamente amplias en datasets pequeños:

- **Random Forest:** `n_estimators` = {100, 200} (número de árboles; valores moderados para control de varianza), `max_depth` = {None, 10, 20} (profundidad máxima; limita sobreajuste), `min_samples_split` = {2, 5} (mínimo de muestras para dividir un nodo; valores bajos favorecen complejidad).
- **SVM:** `C` = {0.1, 1, 10} (parámetro de regularización inversa; rango logarítmico común), `kernel` = {'rbf', 'linear'} (kernels no lineal y lineal para comparar complejidad).
- **k-NN:** `n_neighbors` = {3, 5, 7} (número de vecinos; valores impares para evitar empates), `weights` = {'uniform', 'distance'} (ponderación por distancia mejora en espacios no uniformes).

El proceso se ejecutó independientemente para los dos escenarios: (1) dataset original (con duplicados) y (2) dataset deduplicado.

Los hiperparámetros óptimos se seleccionaron según el mejor F1-macro promedio en validación cruzada. Los resultados detallados de desempeño (accuracy, F1-macro, recall por clase Low) se presentan en la Tabla I de la Sección IV.

IV. RESULTADOS Y DISCUSIÓN

IV-A. Desempeño Comparativo

La Tabla I resume el desempeño de los modelos en ambos escenarios, utilizando las métricas accuracy, F1-macro y recall

Tabla I
COMPARACIÓN DE DESEMPEÑO DE MODELOS EN ESCENARIOS ORIGINAL Y DEDUPLICADO (MEJORES HIPERPARÁMETROS POR GRIDSEARCHCV).

Modelo	Escenario	Accuracy	F1-Macro	Recall (Low)
Random Forest	Original	0,9953	0,9948	0,9884
SVM	Original	0,9623	0,9582	0,9884
k-NN	Original	0,9858	0,9875	0,9884
Random Forest	Deduplicado	0,8235	0,8102	0,8000
SVM	Deduplicado	0,8235	0,8208	0,6000
k-NN	Deduplicado	0,8235	0,8208	0,6000




Figura 4. Importancia de características según impureza de Gini en Random Forest. Temperatura (29.23 %) y pH (26.26 %) acumulan más del 55 % de la contribución predictiva.

para la clase Low (la más crítica en contextos de seguridad alimentaria, ya que representa leche de baja calidad).

La caída drástica de rendimiento al deduplicar (de $\sim 99\%$ a $\sim 82\%$) sugiere que los duplicados exactos (92.16 %) eran mayoritariamente de la misma clase, inflando artificialmente la precisión mediante memorización en lugar de generalización. Random Forest maneja mejor esta situación gracias a su ensemble y bagging, manteniendo un recall razonable en Low (0.80) incluso con pocos datos únicos.

Random Forest superó consistentemente a los demás modelos. SVM mostró dificultades con la clase media debido a solapamiento de rangos en el espacio de características.

IV-B. Importancia de Características

La temperatura y el pH son predictores dominantes y relativamente independientes (correlación 0.24), alineado con su rol bioquímico: el pH indica estabilidad coloidal y actividad microbiana, mientras la temperatura modula la proliferación bacteriana [6], [5]. La multicolinealidad moderada entre variables sensoriales refuerza la ventaja de Random Forest sobre modelos lineales sensibles a esta dependencia.

IV-C. Limitaciones

Aunque los resultados son prometedores, el estudio presenta limitaciones relevantes:

El dataset original contiene un alto porcentaje de duplicados exactos ($\approx 92.16\%$), reduciendo las instancias únicas de 1059

a ≈ 100 –120 tras deduplicación. Esta limpieza, justificada para evitar sesgos y *data leakage*, genera una pérdida significativa de datos y explica la caída en precisión de 99.5 % (original) a 82.4 % (deduplicado), sugiriendo posible sobreestimación en el conjunto crudo.

El tamaño muestral reducido post-deduplicación limita la generalización y aumenta el riesgo de sobreajuste. Además, el dataset es estático, manualmente recolectado, no estrictamente balanceado y carece de variables microbiológicas directas (e.g., conteo bacteriano, patógenos), dinámicas temporales y matices sensoriales complejos.

Estas restricciones resaltan la necesidad de datasets más amplios, diversos y validados en campo para modelos más robustos y aplicables industrialmente.

V. CONCLUSIONES

El aprendizaje automático supervisado permite clasificar la calidad láctea con alta precisión ($>95\%$ en el dataset original). Random Forest destaca por su robustez, interpretabilidad y manejo de multicolinealidad, siendo ideal para despliegue en *edge computing* en granjas inteligentes [3].

REFERENCIAS

- [1] Codex Alimentarius Commission, "Code of hygienic practice for milk and milk products (CAC/RCP 57-2004, rev. 2011)," <https://www.fao.org/fao-who-codexalimentarius>, 2011.
- [2] P. Chapman, J. Clinton, R. Kerber, T. Khabaza, T. Reinartz, C. Shearer, and R. Wirth, "Crisp-dm 1.0: Step-by-step data mining guide," NCR Systems Engineering Copenhagen, Denmark, Tech. Rep., 2000. [Online]. Available: <https://www.crisp-dm.org/crisp-1.0.pdf>
- [3] A. Rajini and T. Sravani, "Machine learning approaches for dairy (milk) quality assurance," in *Proceedings of the 5th International Conference on Data Science, Machine Learning and Applications*, ser. Lecture Notes in Electrical Engineering. Springer, 2024, vol. 1273, pp. 896–902.
- [4] Food and Agriculture Organization of the United Nations, *Milk and Dairy Products in Human Nutrition*. FAO, 2019.
- [5] K. Gandhi, R. Sharma, P. B. Gautam, and B. Mann, *Chemical Quality Assurance of Milk and Milk Products*. Springer, 2020.
- [6] P. Walstra, J. T. M. Wouters, and T. J. Geurts, *Dairy Science and Technology*, 2nd ed. CRC Press, 2005.
- [7] C. C. Aggarwal, *Data Mining: The Textbook*. Springer, 2015.
- [8] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [9] Kaggle, "Milk quality prediction dataset," <https://www.kaggle.com/datasets/cpluzshrijayan/milkquality>, 2023, accessed: 2025-11-16.
- [10] F. Golicolea, M. LAbraña, and M. Yañez, "Proyecto-milk-quality-ml2: Predicción de la calidad de la leche mediante machine learning," <https://github.com/FelipeGoico/Proyecto-Milk-Quality-ML2>, 2026.
- [11] W. McKinney, *Python for Data Analysis: Data Wrangling with pandas, NumPy, and IPython*. O'Reilly Media, 2012.
- [12] T. M. Mitchell, *Machine Learning*. McGraw-Hill, 1997.

- [13] A. C. Müller and S. Guido, *Introduction to Machine Learning with Python: A Guide for Data Scientists*. O'Reilly Media, 2017.
- [14] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.